

Generative KI für 3D-Medizinbildgebung mittels Diffusion Models

Generative AI for 3D Medical Imaging using Diffusion Models

Studienarbeit

vorgelegt von

Sven Beller

2026

Matrikelnummer, Kurs

5102447, TINF23

Betreuer

Malte Tölle

Sperrvermerk

TODO: Anpassen

Die vorliegende Arbeit beinhaltet interne vertrauliche Informationen des Unternehmens ZIEHL-ABEGG SE. Sie ist nur für die Beteiligten am Begutachtungs- und Evaluationsprozess bestimmt. Die Weitergabe des Inhalts der Arbeit im Gesamten oder in Teilen sowie das Anfertigen von Kopien oder Abschriften - auch in digitaler Form - sind grundsätzlich untersagt. Ausnahmen bedürfen der schriftlichen Genehmigung des Unternehmens ZIEHL-ABEGG SE.

Dieser Sperrvermerk gilt unbefristet.

Künzelsau, 1. Januar 2025

Sven Beller

Erklärung

Ich, **Name**, versichere hiermit, dass ich meine **Hier T3_2000/T3_3100 etc** mit dem Thema **Hier Thema** selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ich erkläre zudem, dass ich generative Systeme (Text-, Bild-, Codeerstellung etc.) bei der Erstellung der vorliegenden wissenschaftlichen Arbeit in der nachfolgend beschriebenen Art und dem nachfolgend beschriebenen Umfang verwendet habe.

Ort, Datum

Name

Genutzter Funktionsumfang

Themenerfassung und Strukturierung (Aufgabenstellung/Präzisierung, Forschungsansatz, Gliederung)

Produkt/Tool	Beschreibung / Verwendungsweise
Tool	Ideenfindung und Grobgliederung der Arbeit. Beispiel: Welche Themen existieren über Thema?

Quellenrecherche, -auswahl und -auswertung (durch AI gefundene Quellen; Vorgehen der weiteren Recherche)

Produkt/Tool	Beschreibung / Verwendungsweise
Tool	Vorschläge relevanter Publikationen, anschließende manuelle Validierung. Beispiel: Welche Bücher behandeln das Thema Thema?

Formale Gestaltung, insbesondere Sprache (Prompts/Eingaben; Textgenerierung, Korrektur, Paraphrasieren, Übersetzen, kreatives Schreiben)

Produkt/Tool	Beschreibung / Verwendungsweise
Tool	Grammatik-/Stilkorrektur einzelner Absätze; keine inhaltliche Neuerstellung. Beispiel: Ist der folgende Satz grammatikalisch richtig?

Abstract

This is the abstract in English.

Zusammenfassung

Dies ist die Zusammenfassung auf Deutsch.

Inhaltsverzeichnis

Abbildungsverzeichnis	VIII
Tabellenverzeichnis	IX
Nomenklatur	XI
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung	1
1.3 Vorgehensweise	1
2 Medizinische Bildgebung	2
2.1 Bildgebende Verfahren	2
2.2 NIfTI	2
3 Künstliche Intelligenz	3
3.1 Definition Künstliche Intelligenz	3
3.1.1 Definition Intelligenz	4
3.1.2 Schwache und Starke KI	4
3.2 Maschinelles Lernen	5
3.2.1 Diskriminative Modelle	5
3.3 Generative Modelle	5
3.3.1 GANs	6
3.3.2 VAE	6
3.3.3 Diffusion Model	6
3.4 Convolutional Neural Network	7
3.5 U-Net	7
3.6 Einsatzmöglichkeiten in der Medizin	7

4	Datenqualität und ethische Aspekte	9
4.1	Kriterien für realistische Bilddaten	9
4.2	Risiken und Grenzen synthetischer Daten	9
4.3	Datenschutz	9
4.4	Bewertungsmetriken	9
4.4.1	Fréchet Inception Distance	9
4.4.2	SSIM	10
4.4.3	PSNR	10
4.4.4	LPIPS	10
4.4.5		10
5	Vorgehensweise	11
5.1	Verwendete Werkzeuge	11
5.2	Ergebnis	11
6	Schlussfolgerung	12
6.1	Fazit	12
6.2	Ausblick	12
	Literaturverzeichnis	XIV
A	Anhang A	XVII

Abbildungsverzeichnis

2.1	NIfTI-Header [3, S. 76]	2
3.1	Markov-Kette erster Ordnung [17, S. 609]	6
3.2	Darstellung der Vorwärts- und Rückwärtsprozesse	7
3.3	U-Net Architektur [18, S. 2]	8
4.1	Darstellung der Fréchet Inception Distance (FID)-Berechnung [23, S. 130] . .	10

Tabellenverzeichnis

Nomenklatur

Lateinische Buchstaben

A	m^2	Fläche
$\vec{a}$	m/s^2	Beschleunigung
a	m/s	Schallgeschwindigkeit
c_p	J/(kgK)	spezifische isobare Wärmekapazität
c_v	J/(kgK)	spezifische isochore Wärmekapazität
E	J	innere Energie
e	J/kg	spezifische innere Energie
g	m/s^2	Erdbeschleunigung
H	J	Enthalpie
h	J/kg	spezifische Enthalpie
k	J/K	Boltzmann-Konstante $(k = 1,3807 \cdot 10^{-23})$
m	kg	Masse
N_A	mol^{-1}	Avogadro-Konstante $(N_A = 6,0021318 \cdot 10^{23})$
$\vec{n}$	-	nach außen gerichteter Normaleneinheitsvektor
n	-	Polytropenexponent
P	J/s	Leistung
p	N/m^2	Druck
Q	J	Wärme
$\dot{Q}$	J/s	Wärmestrom
q	J/kg	bezogene Wärme
$\dot{q}$	J/(kg s)	bezogener Wärmestrom
R	J/(kgK)	spezielle Gaskonstante
R_m	J/(molK)	universelle Gaskonstante $(R_m = 8,31441)$
T	K	Temperatur
t	s	Zeit
u, v, w	m/s	Geschwindigkeitskomponenten im kartesischen Koordinatensystem
$\vec{V}$	m/s	Geschwindigkeitsvektor
V	m^3	Volumen
v	m^3/kg	spezifisches Volumen
W	J	Arbeit
x, y, z	m	kartesische Koordinaten
z	m	Höhe

Griechische Buchstaben

η	Pa s	dynamische Viskosität (Scherviskosität)
κ	-	Isentropenexponent
ν	m^2/s	kinematische Viskosität
γ	-	Polytropenverhältnis
ρ	kg/m^3	Dichte
τ_w	N/m^2	Wandschubspannung
$\vec{\omega}$	s^{-1}	Winkelgeschwindigkeit

Tiefgestellte Indizes

0	Ruhegröße
n	normal
t	tangential

Hochgestellte Indizes

*	kritischer Zustand (LAVAL-Zustand)
---	------------------------------------

Dimensionslose Kennzahlen

Ma	$:= \ \vec{V}\ /a$	Mach-Zahl
Ma*	$:= \ \vec{V}\ /a^*$	kritische Mach-Zahl
Re	$:= \ \vec{V}\ L/\nu$	Reynolds-Zahl

Operatoren, Funktionen und Symbole

Abkürzungen

KI	Künstliche Intelligenz
NLP	Natural Language Processing
DGM	Deep generative model
NIfTI	Neuroimaging Informatics Technology Initiative
NIH	National Institutes of Health
CNN	Convolutional Neural Network
FID	Fréchet Inception Distance
IS	Inception score
GANs	Generative Adversarial Networks

IQMs	Image Quality Metrics
FR	full-reference
RR	reduced-reference
NR	no-reference
SSIM	SSIM
PSNR	Peak Signal-to-Noise Ratio

1 Einleitung

TODO: neu schreiben/bisschen abändern

In der Medizin werden mithilfe von 3D-Bildgebung bessere Diagnosen von Krankheiten und genauere Eingriffe durchgeführt. Dabei bringt die steigende Entwicklung von generativer KI neue Möglichkeiten für medizinische Bilddaten.

Diffusion Models haben sich als leistungsfähige Methode zur realistischen Bildsynthese etabliert. In der datengetriebenen Medizin besteht ein wachsender Bedarf an hochwertigen, vielfältigen und datenschutzkonformen Bilddaten, insbesondere für das Training von KI-Systemen. Dieses Projekt widmet sich der Entwicklung eines Diffusion Models zur Generierung synthetischer 3D-medizinischer Volumendaten, die für Forschungszwecke, Augmentierung und Trainingsprozesse genutzt werden können.

1.1 Problemstellung

Für generative KI-Modelle besteht ein wachsender Bedarf an Daten, um ein Model darauf zu trainieren. Allerdings ist die Verfügbarkeit dieser Daten eingeschränkt durch Datenschutzbestimmungen und an der Bildakquise von seltenen Krankheiten. Durch diese Limitierung besteht eine Erschwerung des Trainieren solcher Modelle. Es besteht daher ein Bedarf an synthetischen aber realistischen Bilddaten, die sowohl qualitativ und ethisch vertretbar sind.

1.2 Zielsetzung

Ziel dieser Studienarbeit ist die Entwicklung eines generativen KI-Systems, das mittels Diffusion Models realistische 3D-medizinische Bilddaten erzeugt.

1.3 Vorgehensweise

2 Medizinische Bildgebung

2.1 Bildgebende Verfahren

2.2 NIfTI

Das Neuroimaging Informatics Technology Initiative (NIfTI)-Format (.nii, .nii.gz) wurde in den frühen 2000er Jahren vom National Institutes of Health (NIH) entwickelt und hat sich als Standardformat in der neuroimaging-basierten Forschung etabliert. Es ist speziell für die Verarbeitung volumetrischer 3D-Bilddaten ausgelegt und daher geeignet für beispielsweise MRT-Gehirnuntersuchungen [1, S. 203]. NIfTI ist ein Rasterformat, das Daten in dreidimensionaler Form als Voxel speichert also als Pixel mit einer definierten Breite, Höhe und Tiefe [2, S. 4]. Dabei werden in den ersten drei Dimensionen die räumlichen Koordinaten x , y und z gespeichert, während die vierte Dimension für den Zeitpunkt t reserviert ist [3, S. 76]. Der Header einer NIfTI-Datei umfasst im .nii-Format 352 Bytes [3, S. 76]. In Abb. 2.1 ist ein Beispiel-Header zu sehen, welcher zeigt, welche Metadaten gespeichert werden. So ist beispielsweise im Parameter ImageSize die Auflösung des MRT-Scans abzulesen, in diesem Fall 256x156x256. Im Gegensatz zu Formaten

Parameters	Value
Filename	group00001_T1w_CSF_probability.nii
Filesize	40894816
Description	'DAD210715'
ImageSize	[256 156 256]
xPixelDimensions	[1 1.3000 1]
Datatype	'single'
BitsPerPixel	32
SpaceUnits	'Millimeter'
TimeUnits	'Second'
MultiplicativeScaling	1

Abb. 2.1: NIfTI-Header [3, S. 76]

wie JPEG, das eine verlustbehaftete Kompression verwendet und dadurch relevante Bildinformationen beeinträchtigen kann, unterstützt NIfTI eine verlustfreie Kompression [1, S. 203].

3 Künstliche Intelligenz

TODO: Titel gegebenenfalls anpassen **Schreibe: Schreiben worüber in diesem Kapitel behandelt wird**

3.1 Defintion Künstliche Intelligenz

Der Begriff Künstliche Intelligenz (KI) kann je nach Anwendungsgebiet eine andere Definition haben. Ein Buch beschreibt die KI als ein Forschungsgebiet [4, S. 5]. Jedoch wird die KI in dieser Studienarbeit beschrieben als eine Methode, dass Computern die Intelligenz des Menschen vorgibt und somit menschenähnlich zu denken [5, S. 3] [6, S. 42].

TODO: Agenten nochmal neu definieren. Siehe S. 17 Knowledge Science - Grundlagen

3.1.1 Defintion Intelligenz

Die Intelligenz kann als eine Sammlung von Eigenschaften verstanden werden und es ist das Ziel dass diese Eigenschaften nachgebaut werden. Wissenschaftler in der KI haben die folgenden Eigenschaften zu der Intelligenz definiert: [7, S. 1 f.]

- **Wahrnehmung:** Die Beobachtung seiner Umwelt mithilfe von Sensoren.
- **Schlussfolgern:** Aus bekannten Informationen rationale Entscheidungen ziehen auch bei Unsicherheit.
- **Handeln:** Aus bekannten Informationen gezielt handeln und Werkzeuge nutzen oder entwickeln.
- **Planung und Problemlösung:** Schritte planen, um ein Ziel zu erreichen oder ein Problem zu lösen.
- **Kommunikation:** Mit anderen Systemen oder Menschen kommunizieren.
- **Anpassungsfähigkeit und Lernen:** Aus Erfahrungen lernen und sich an neue Situationen anpassen.
- **Autonomie:** Eigene Ziele setzen und selbst entscheiden, wie man sie erreicht.
- **Kreativität:** Neue Wege zur Lösung von Problemen finden.
- **Reflexion und Bewusstheit:** Über eigene Entscheidungen und Prozesse reflektieren.
- **Ästhetik:** Bei Entscheidungen auch ästhetische Aspekte berücksichtigen.
- **Organisation:** Mit anderen zusammenarbeiten und sich abstimmen.

Schreibe: Über die Punkte angehen, wie diese die Intelligenz beschreibe **TODO: Bearbeiten** Anschließend zu der Intelligenz zählt das rationale Denken. Beim rationalen Denken wird auf Basis des bekannten Informationen auch mit Unsicherheit, die bestmögliche Entscheidung getroffen. Das System soll auch auf diese Entscheidungen handeln und selbstständig weiterlernen. Ein solches System wird als *intelligenter Agent* bezeichnet [8, S. 4].

3.1.2 Schwache und Starke KI

Wie intelligent eine KI ist, wird unter Wissenschaftler zwischen einer *schwachen (weak)* / *beschränkten (narrow)* und *starken (strong)* / *allgemeine (general)* KI unterschieden [9, S. 1]. Eine schwache KI ist spezifisch für eine Domäne entwickelt, die die menschliche Intelligenz dort simuliert [9, S. 1] [10, S. 7]. Diese können ein oder wenige spezifische Probleme sehr gut lösen. Allerdings kann die schwache KI bekannte Lösungsmuster auf

neue Probleme nicht in andere Domänen übertragen [10, S. 7]. Momentan können alle KI-Systeme als eine schwache KI bewertet werden, da sie jeweils spezifisch zu ihrer Domäne sind. Eine beispiel Domäne ist die Natural Language Processing (NLP) [9, S. 1]. Die schwache KI wird noch mal in zwei weitere Kategorien verfasst und unterscheiden sich dabei, mit welcher Methode sie trainiert werden. Diese sind die *symbolische KI* und *nicht-symbolische KI*. In der symbolischen KI wird diese mithilfe von Deduktion trainiert. Heißt auf logische Regeln. Während die nicht-symbolische KI mit Induktion also anhand von vorhandene Daten lernt [5, S. 4 f.]. Eine starke KI hingegen besitzt die Fähigkeit die menschliche Intelligenz zu emulieren. Dies bedeutet, dass sie selbständig fungiert und somit auch selbstbewusst ist. Dabei kann die starke KI Probleme lösen, ohne davor dafür trainiert zu sein [10, S. 7] [11, S. 17]. Dies würde dann zu einer technologischen Singularität führen und einer Superintelligenz [9, S. 1] [10, S. 7] [11, S. 17]. Eine technologische Singularität ist der Punkt, an dem die KI nicht mehr vom Menschen kontrolliert werden kann [11, S. 18]. Allerdings gibt bis jetzt keine starke KI und somit ein theoretisches Konzept. Es wird jedoch in Science-Fiction-Werke angewendet [9, S. 1] [11, S. 17 f.] [5, S. 4].
TODO: Neu durchlesen

3.2 Maschinelles Lernen

Zu diesen Methoden gehört das maschinelle Lernen, wobei der Computer selbständig Wissen generiert aus Erfahrungen. Dabei wird der Computer durch Beispiele trainiert worraus dieser dann Muster abgeleitet werden. Diese Muster werden dann auf die jeweilige Situation angewendet [6, S. 42]. **Schreibe: Was ist Intelligenz Schreibe: Je weniger Eigenschaften gebracuth werden desto besser können Ergebnisse sein**

3.2.1 Diskriminative Modelle

3.3 Generative Modelle

Generative Modelle hingegen sind in der Lage neue synthetische Daten zu generieren. Sie lernen, wie die Daten strukturiert sind und können durch das Erlernen dieser Struktur neue Daten generieren, die dieser Struktur folgen [12, S. 112].

Generative Model werden auch als Deep generative model (DGM)s bezeichnet. Unter ein DGM wird ein neuronales Netzwerk verstanden, dass die Wahrscheinlichkeitsverteilung von hoch dimensionalen Daten, wie Bilder, Text oder Audio, lernt [13, S. 16]. Sie besitzen eine hohe Anzahl von versteckten Schichten aus Neuronen, um das Erlernen der hochdimensionalen Datenverteilungen zu ermöglichen. Allerdings sind sie sehr rechenaufwendig und die Performanz ist stark abhängig von *Hyperparametern*. Hyperparameter beziehen sich auf Einstellungen, die vor dem Training festgelegt werden und den Lernprozess steuern. Dazu gehören die Netzwerkarchitektur, die Wahl der Zielfunktion, Regularisierungstechniken sowie Trainingsalgorithmen [14, S. 2].

3.3.1 GANs

3.3.2 VAE

3.3.3 Diffusion Model

Ein *Diffusion Model* oder auch *Diffusions-Wahrscheinlichkeitsmodell* ist ein generatives Modell, das zur Klasse der latenten Variablenmodelle gehört [15, S. 153] [12, S. 114]. Das grundlegende Prinzip besteht darin, einen Diffusionsprozess umzukehren, bei dem schrittweise Rauschen zu den Daten hinzugefügt wird. Durch die Umkehrung dieses Prozesses kann das Modell aus verrauschten Signalen Daten rekonstruieren und so neue Daten generieren. Dafür wird eine parametrisierte Markov-Kette mittels Variationsinferenz trainiert, deren Übergänge lernen, den Diffusionsprozess umzukehren [15, S. 153] [16, S. 2].

Eine Markov-Kette ist ein stochastischer Prozess, wo der zukünftige Zustand nur vom aktuellen Zustand abhängt und nicht von der Vergangenheit. Somit kann eine Sequenz von zufälligen Variablen $x_0, x_1, \dots, x_T$ beschrieben werden als:

$$p(x_t | x_0, \dots, x_{t-1}) = p(x_t | x_{t-1}), \quad t = 1, \dots, T \quad (3.1)$$

Hier bei gilt für t als die Zeit und x_t als der Zustand zum Zeitpunkt t . Aufgrund der Markov-Eigenschaft kann die gemeinsame Wahrscheinlichkeit der gesamten Sequenz $x_{1:T}$ gegeben x_0 als Produkt der Übergangswahrscheinlichkeiten faktorisiert werden: [15, S. 153] [17, S. 608 f.].

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}) \quad (3.2)$$

Eine Markov-Kette wird in Abb. 3.1 dargestellt. Diese wird auch als eine Markov-Kette der ersten Ordnung beschrieben [17, S. 609]. Hinzu wird die inverse von $x_0, x_1, \dots, x_T$ mit




Abb. 3.1: Markov-Kette erster Ordnung [17, S. 609]

$x_T, x_{T-1}, \dots, x_0$ ebenfalls als eine Markov-Kette bezeichnet [15, S. 154]. Die Eigenschaft der Gedächtnislosigkeit der Markov-Kette erweist sich als geeignet für Diffusionsprozesse, da jeder Diffusionsschritt nur vom vorherigen Zustand abhängt.

Die Abb. 3.2 stellt den Vorwärts- und Rückwärtsprozess an einem Bild dar. Der Vorwärtsprozess (engl. *Forward Process*) ist fest vorgegeben und wird nicht trainiert und dient als Encoder. Er fügt einem Bild x_0 bis x_T schrittweise Gaußsches Rauschen hinzu, bis am Ende nur noch reines Rauschen übrig ist. Dieses Rauschen wird in jedem Schritt t etwas hinzugefügt und wird beschrieben mit

$$x_t = \alpha_t x_{t-1} + \beta_t \epsilon_t, \quad (3.3)$$




Abb. 3.2: Darstellung der Vorwärts- und Rückwärtsprozesse

wobei $\epsilon_i \sim \mathcal{N}(0, I)$ zufälliges Gaußsches Rauschen ist. Die Parameter α_i und β_i steuern, wie viel vom vorherigen Bild erhalten bleibt und wie viel Rauschen hinzukommt.

Der praktische Vorteil ist, dass wir x_i direkt aus dem Originalbild x_0 berechnen können:

$$x_t = \bar{\alpha}_t x_0 + \sqrt{1 - \bar{\alpha}_t^2} \epsilon, \quad (3.4)$$

mit $\bar{\alpha}_t = \prod_{k=1}^t \alpha_k$. Das bedeutet, wir müssen nicht alle Zwischenschritte durchlaufen, sondern können direkt zu einem beliebigen Rauschzustand springen.

Nach genügend vielen Schritten ($L \rightarrow \infty$) ist das Originalbild vollständig zerstört und wir erhalten eine Standardnormalverteilung $\mathcal{N}(0, I)$. Von diesem Punkt aus lernt dann das neuronale Netzwerk, den Prozess umzukehren. **TODO: neu durchlesen**

Sampling

3.4 Convolutional Neural Network

3.5 U-Net

U-Net ist eine Convolutional Neural Network (CNN)-Architektur, die für die biomedizinische Bildsegmentierung entwickelt wurde. Trotz ihres ursprünglichen Anwendungsgebietes dient die Architektur eine zentrale Rolle im Denoising-Schritt in Diffusionsmodellen [18, S. 2]. Die U-Net Architektur erweist sich als vorteilhaft für die generative KI, da sie flexibel ist für verschiedene Datenmodellierungen. Dazu gehören Bild, Audio, Video, Text sowie 3D-volumetrische Daten [19, S. 2]. In Abb. 3.3 wird die Architektur dargestellt. Das Grundprinzip von U-Net basiert auf einer symmetrischen Encoder-Decoder-Struktur. Auf der linken Hälfte ist der Encoder. Der Encoder folgt dem Prinzip eines convo

3.6 Einsatzmöglichkeiten in der Medizin




Abb. 3.3: U-Net Architektur [18, S. 2]

4 Datenqualität und ethische Aspekte

4.1 Kriterien für realistische Bilddaten

4.2 Risiken und Grenzen synthetischer Daten

4.3 Datenschutz

4.4 Bewertungsmetriken

Um die Qualität von durch generativen Modelle erstellten Bildern objektiv zu beurteilen, kommen sogenannte Image Quality Metrics (IQMs) zum Einsatz. IQMs erlauben einen objektiven Rahmen zur Bewertung von Eigenschaften wie Auflösung, Rauschen und Artefakte. Gegenüber subjektiven Bewertungen durch Menschen haben IQMs den Vorteil, dass sie standardisiert, quantifizierbar und reproduzierbar sind und somit einen systematischen Vergleich verschiedener generativer Modelle ermöglicht. IQMs lassen sich in drei verschiedenen Kategorien einordnen: full-reference (FR), reduced-reference (RR) und no-reference (NR). Diese Unterscheidung ist im Kontext von Diffusionsmodellen besonders wichtig. Bei Aufgaben wie Bildrekonstruktion oder Denoising, bei denen ein Originalbild als Referenz vorliegt, kommen FR-Metriken wie SSIM (SSIM) oder Peak Signal-to-Noise Ratio (PSNR) zum Einsatz. Bei der freien Text-to-Image-Generierung hingegen existiert kein eindeutiges Referenzbild, weshalb hier häufig auf NR-Metriken oder semantische Maße wie den FID oder den CLIP-Score zurückgegriffen wird [20, S. 1]. **TODO: mehr quelle zu IQM finden**

4.4.1 Fréchet Inception Distance

Die FID ist eine Metrik zur Bewertung der Qualität Generative Adversarial Networks (GANs) und wurde 2017 von Heusel et al. eingeführt. Sie stellt eine Weiterentwicklung des Inception score (IS) dar, dessen Schwachpunkt darin besteht, dass er die statistische Verteilung realer Bilder nicht in die Bewertung einbezieht [21, S. A1]. Die Berechnung der FID erfolgt in zwei Schritten. Zunächst werden sowohl reale als auch generierte Bilder durch ein vortrainiertes CNN geleitet [22, S. 2]. Aus einer intermediären Schicht dieses Netzwerks werden abstrakte Merkmalsvektoren gewonnen, die als visuelle Repräsentationen der Bilder dienen [23, S. 130]. Im zweiten Schritt werden diese Merkmale statistisch beschrieben. Für die realen Bilder wird der Mittelwert μ_{data} also der durchschnittliche Merkmalsvektor sowie die Kovarianzmatrix Σ_{data} berechnet, welche beschreibt, wie

stark die Merkmale untereinander variieren. Dasselbe geschieht für die generierten Bilder, die durch μ_g und Σ_g beschrieben werden [23, S. 130] [21, S. A1]. Anschließend wird die Fréchet Distanz zwischen den beiden so beschriebenen Verteilungen berechnet [24, S. 2]:

$$\text{FID} = \|\mu_{data} - \mu_g\|^2 + \text{Tr}\left(\Sigma_{data} + \Sigma_g - 2\left(\Sigma_{data}\Sigma_g\right)^{1/2}\right), \quad (4.1)$$

Die Formel Gl. (4.1) besteht aus zwei Teilen. Der erste Term $\|\mu_{data} - \mu_g\|^2$ misst, wie weit die durchschnittlichen Merkmale realer und generierter Bilder voneinander abweichen. Der zweite Term vergleicht die Kovarianzmatrizen beider Verteilungen und erfasst damit, ob die generierten Bilder eine ähnliche Vielfalt und Struktur aufweisen wie die realen cite [24, S. 2]. In Abb. 4.1 wird der Prozess dargestellt. Der Generator G erzeugt Bilder, die




Abb. 4.1: Darstellung der FID-Berechnung [23, S. 130]

zusammen mit den Trainingsbildern durch das CNN D geleitet werden, um die statistischen Kenngrößen μ_{data} , Σ_{data} , μ_g und Σ_g zu extrahieren und daraus den FID-Wert zu berechnen. Ein niedriger FID-Wert zeigt an, dass beide Verteilungen eng beieinanderliegen, was auf hohe Bildqualität und ausreichende Diversität hindeutet [23, S. 130].

4.4.2 SSIM

4.4.3 PSNR

4.4.4 LPIPS

4.4.5

5 Vorgehensweise

5.1 Verwendete Werkzeuge

5.2 Ergebnis

6 Schlussfolgerung

6.1 Fazit

6.2 Ausblick

Literatur

- [1] Sridaran Rajagopal u. a., Hrsg. *Artificial Intelligence Based Smart and Secured Applications: 4th International Conference, ASCIS 2025, Gujarat, India, September 11–13, 2025, Revised Selected Papers, Part III*. en. Bd. 2821. Communications in Computer and Information Science. Cham: Springer Nature Switzerland, 2026. ISBN: 978-3-032-17839-8 978-3-032-17840-4. DOI: 10.1007/978-3-032-17840-4. URL: <https://link.springer.com/10.1007/978-3-032-17840-4> (besucht am 18.02.2026).
- [2] Ahmed Elhadad, Mona Jamjoom und Hussein Abulkasim. „Reduction of NIFTI files storage and compression to facilitate telemedicine services based on quantization hiding of downsampling approach“. en. In: *Scientific Reports* 14.1 (März 2024), S. 5168. ISSN: 2045-2322. DOI: 10.1038/s41598-024-54820-4. URL: <https://www.nature.com/articles/s41598-024-54820-4> (besucht am 18.02.2026).
- [3] Department of Computer Applications, Kalasalingam Academy of Research and Education (Deemed to be University), Krishnankoil, Tamil Nadu, India. u. a. „An Medical Image File Formats and Digital Image Conversion“. en. In: *International Journal of Engineering and Advanced Technology* 9.1s4 (Dez. 2019), S. 74–78. ISSN: 22498958. DOI: 10.35940/ijeat.A1093.1291S419. URL: <https://www.ijeat.org/portfolio-item/A10931291S419/> (besucht am 18.02.2026).
- [4] Harald Nahrstedt. *Algorithmen für Ingenieure*. de. Wiesbaden: Springer Fachmedien Wiesbaden, 2018. ISBN: 978-3-658-19298-3 978-3-658-19299-0. DOI: 10.1007/978-3-658-19299-0. URL: <http://link.springer.com/10.1007/978-3-658-19299-0> (besucht am 10.10.2025).
- [5] Zhen LLeo" Liu. *Artificial Intelligence for Engineers: Basics and Implementations*. en. Cham: Springer Nature Switzerland, 2025. ISBN: 978-3-031-75952-9 978-3-031-75953-6. DOI: 10.1007/978-3-031-75953-6. URL: <https://link.springer.com/10.1007/978-3-031-75953-6> (besucht am 06.10.2025).
- [6] Andreas Kohne u. a. *Chatbots: Aufbau und Anwendungsmöglichkeiten von autonomen Sprachassistenten*. de. Wiesbaden: Springer Fachmedien Wiesbaden, 2020. ISBN: 978-3-658-28848-8 978-3-658-28849-5. DOI: 10.1007/978-3-658-28849-5. URL: <http://link.springer.com/10.1007/978-3-658-28849-5> (besucht am 06.10.2025).
- [7] Vasant Honavar. „Artificial Intelligence: An Overview“. en. In: (). (Besucht am 07.10.2025).
- [8] Stuart J. Russell und Peter Norvig. *Artificial intelligence: a modern approach*. en. Third edition, Global edition. Prentice Hall series in artificial intelligence. Boston

- Columbus Indianapolis: Pearson, 2016. ISBN: 978-0-13-604259-4 978-1-292-15397-1. (Besucht am 07.10.2025).
- [9] Paolo Bory, Simone Natale und Christian Katzenbach. „Strong and weak AI narratives: an analytical framework“. en. In: *AI & SOCIETY* 40.4 (Apr. 2025), S. 2107–2117. ISSN: 0951-5666, 1435-5655. DOI: 10.1007/s00146-024-02087-8. URL: <https://link.springer.com/10.1007/s00146-024-02087-8> (besucht am 14.10.2025).
 - [10] Carsten Lanquillon und Sigurd Schacht. *Knowledge Science - Grundlagen: Methoden der Künstlichen Intelligenz für die Wissensextraktion aus Texten*. de. Wiesbaden: Springer Fachmedien Wiesbaden, 2023. ISBN: 978-3-658-41688-1 978-3-658-41689-8. DOI: 10.1007/978-3-658-41689-8. URL: <https://link.springer.com/10.1007/978-3-658-41689-8> (besucht am 06.10.2025).
 - [11] Robert Ciesla. *The Book of Chatbots: From ELIZA to ChatGPT*. en. Cham: Springer Nature Switzerland, 2024. ISBN: 978-3-031-51003-8 978-3-031-51004-5. DOI: 10.1007/978-3-031-51004-5. URL: <https://link.springer.com/10.1007/978-3-031-51004-5> (besucht am 14.10.2025).
 - [12] Stefan Feuerriegel u. a. „Generative AI“. en. In: *Business & Information Systems Engineering* 66.1 (Feb. 2024), S. 111–126. ISSN: 2363-7005, 1867-0202. DOI: 10.1007/s12599-023-00834-7. URL: <https://link.springer.com/10.1007/s12599-023-00834-7> (besucht am 14.02.2026).
 - [13] Chieh-Hsin Lai u. a. *The Principles of Diffusion Models*. en. arXiv:2510.21890 [cs]. Okt. 2025. DOI: 10.48550/arXiv.2510.21890. URL: <http://arxiv.org/abs/2510.21890> (besucht am 14.02.2026).
 - [14] Lars Ruthotto und Eldad Haber. „An introduction to deep generative modeling“. en. In: *GAMM-Mitteilungen* 44.2 (Juni 2021), e202100008. ISSN: 0936-7195, 1522-2608. DOI: 10.1002/gamm.202100008. URL: <https://onlinelibrary.wiley.com/doi/10.1002/gamm.202100008> (besucht am 15.02.2026).
 - [15] Takeshi Okadome. *Essentials of Generative AI*. en. Singapore: Springer Nature Singapore, 2025. ISBN: 978-981-96-0028-1 978-981-96-0029-8. DOI: 10.1007/978-981-96-0029-8. URL: <https://link.springer.com/10.1007/978-981-96-0029-8> (besucht am 15.02.2026).
 - [16] Jonathan Ho, Ajay Jain und Pieter Abbeel. *Denoising Diffusion Probabilistic Models*. en. arXiv:2006.11239 [cs]. Dez. 2020. DOI: 10.48550/arXiv.2006.11239. URL: <http://arxiv.org/abs/2006.11239> (besucht am 15.02.2026).
 - [17] Christopher M. Bishop. *Pattern recognition and machine learning*. en. Information science and statistics. New York: Springer, 2006. ISBN: 978-0-387-31073-2.
 - [18] Olaf Ronneberger, Philipp Fischer und Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. en. arXiv:1505.04597 [cs]. Mai 2015. DOI: 10.48550/arXiv.1505.04597. URL: <http://arxiv.org/abs/1505.04597> (besucht am 22.02.2026).
 - [19] Marvin John Ignacio u. a. „Revisiting U-Net: a foundational backbone for modern generative AI“. en. In: *Artificial Intelligence Review* 59.2 (Nov. 2025), S. 45. ISSN:

- 1573-7462. DOI: 10.1007/s10462-025-11450-0. URL: <https://link.springer.com/10.1007/s10462-025-11450-0> (besucht am 24.02.2026).
- [20] Pinar Civicioglu und Erkan Besdok. „Image discrimination robustness of classical image quality metrics: an analysis on MAE, MSE, ERGAS, LMSE, SSIM, SAM, UIQI, PSNR, NIQE, PIQE, SNR, VIF, FSIM, GMSD, and NCC“. en. In: *Quality & Quantity* (Okt. 2025). ISSN: 0033-5177, 1573-7845. DOI: 10.1007/s11135-025-02404-3. URL: <https://link.springer.com/10.1007/s11135-025-02404-3> (besucht am 01.03.2026).
- [21] Martin Heusel u. a. *GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium*. en. arXiv:1706.08500 [cs]. Jan. 2018. DOI: 10.48550/arXiv.1706.08500. URL: <http://arxiv.org/abs/1706.08500> (besucht am 01.03.2026).
- [22] Christian Szegedy u. a. *Rethinking the Inception Architecture for Computer Vision*. en. arXiv:1512.00567 [cs]. Dez. 2015. DOI: 10.48550/arXiv.1512.00567. URL: <http://arxiv.org/abs/1512.00567> (besucht am 01.03.2026).
- [23] Peng Long und Xiaozhou Guo. *Generative Adversarial Network: Principle and Practice*. en. Singapore: Springer Nature Singapore, 2026. ISBN: 978-981-96-9403-7 978-981-96-9404-4. DOI: 10.1007/978-981-96-9404-4. URL: <https://link.springer.com/10.1007/978-981-96-9404-4> (besucht am 01.03.2026).
- [24] D. C. Dowson und B. V. Landau. „The Fréchet Distance between Multivariate Normal Distributions“. In: *Journal of Multivariate Analysis* 12.3 (1982), S. 450–455. ISSN: 0047-259X. DOI: 10.1016/0047-259X(82)90077-X.

A Anhang A

Weitere Abbildungen